FusionSeg:SViT-C 双分支混合编码及多分支跨特征注意力解码的皮肤病变分割模型

摘要

针对现有皮肤病变分割难以兼顾**局部细节**与**全局语义**建模的问题，本文提出 **SViT-C 双分支混合编码及多分支跨特征注意力解码**的皮肤病变分割模型 **FusionSeg**。该系统采用 **SViT-C 双分支混合编码器 (SwinViT-CNN)**，依靠 **SwinTransformer-CNN**（卷积神经网络，擅长提取局部细节/Transformer 架构，擅长全局语义建模，二者互补）并行提取多尺度特征，通过**全局特征恢复模块**过滤冗余语义，由集成极化注意力的**双分支融合 (Dual-Branch Fusion, DBF) 模块**融合局部与全局特征；依托**多分支跨特征注意力 (Multi-Branch Deep Cross-Feature Attention, MBCFA) 解码器**强化多尺度特征表达，精准优化病变边界。在 ISIC2017、ISIC2018 和 PH^2 三大公开数据集上的实验结果显著优于 U-Net[12]、TransUNet[3] 等主流方法，**消融实验**进一步验证了各模块的有效性。该模型可辅助皮肤科开展病变早期筛查，具备良好的临床应用价值。本项目的核心算法 FusionSeg 是基于团队原创中科院二区论文 SVMB-Net（IEEE JBHI, 2025）的实现，有申请中的专利。

关键词：皮肤病变分割、SViT-C 双分支混合编码器、全局特征恢复、双分支融合模块、多分支深度跨特征注意力

目录

1 研究背景及意义 **3**

2 项目研究的内容和技术路线 **3**

2.1 研究内容 3

2.2 创新点一：SViT-C 双分支混合编码器 4

2.2.1 局部 CNN 残差特征提取 5

2.2.2 全局 Swin 多窗口注意力特征提取 5

2.2.3 全局特征恢复模块 6

2.2.4 DBF 双分支融合模块 7

2.3 创新点二：多分支深度跨特征注意力（MBCFA）解码器 8

2.3.1 平行多尺度深度卷积（MBC） 9

2.3.2 交叉特征注意力（CFA） 9

2.4 FusionSeg 整体运行流程 10

2.5 实验细节与结果 11

2.5.1 实验结果与分析 11

2.5.2 消融实验分析 16

3 应用前景、社会价值与改进方向 **19**

3.1 应用前景与社会价值 19

3.2 存在问题与改进方向 19

4 原创性说明 **20**

参考文献 **21**

1 研究背景及意义

皮肤癌为全球高发恶性肿瘤，黑色素瘤致死率高、早筛难度大，精准病变分割是临床早诊关键。人工诊断存在主观性强、效率低、资源不均等痛点，现有单架构分割模型存在固有缺陷：CNN 难以建模长距离语义依赖，Transformer 易丢失局部细节、特征冗余，无法同时保障分割精度与边界完整性。为此本文提出 **FusionSeg** 模型，以**双分支混合编码、多维度注意力解码**为核心，兼顾局部与全局特征，提升分割精度与鲁棒性，为基层皮肤癌智能筛查提供支撑。

2 项目研究的内容和技术路线

2.1 研究内容

针对皮肤病变分割中单一 CNN/Transformer 无法同时兼顾局部细节与全局语义的核心痛点，本文聚焦 **SViT-C 双分支混合编码、多分支跨特征注意力解码的 FusionSeg 模型**的设计与验证，目标是实现复杂临床场景下高精度高鲁棒性皮肤病变自动分割，具体研究内容如下：

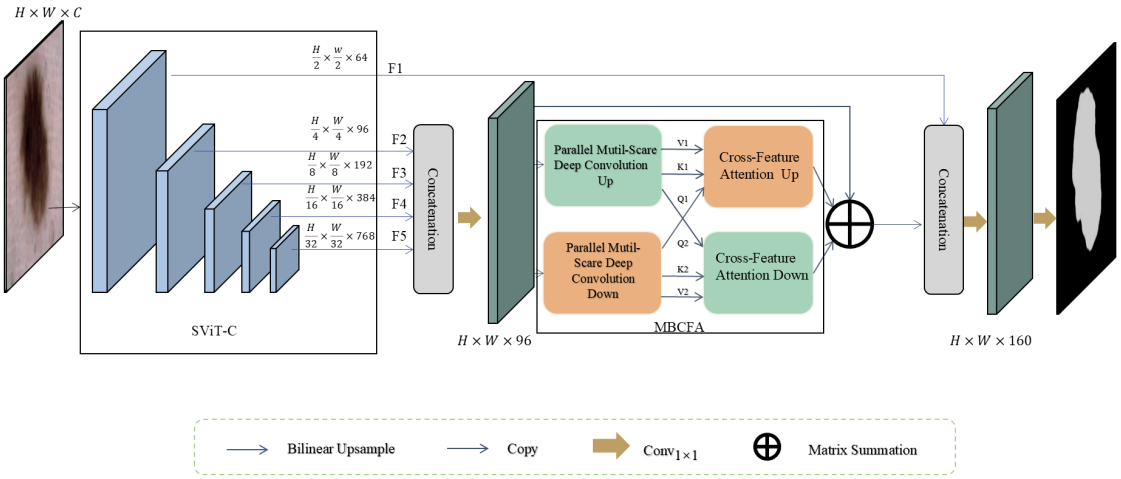


图 1: FusionSeg 网络整体架构图

由图 1 所示：FusionSeg 采用 SViT-C 双分支混合编码器与 MBCFA 多分支注意力解码器的端到端架构。编码器侧，CNN 残差分支提取局部细粒度特征，Swin Transformer 分支建模长距离语义，两分支特征逐层经 DBF 模块以 CBAM 通道-空间注意力与 PAM 位置注意力融合校准，Swin 分支最后一层额外经全局特征恢复模块过滤冗余噪声，输出 $F_1 \sim F_5$ 共 5 层多尺度特征（F_1 为 CNN 直出边界特征，$F_2 \sim F_5$ 为双分支融合特征）。解码器侧，$F_2 \sim F_5$ 上采样拼接降维后送入 MBCFA，先由多分支深度卷积（MBC）提取多感受野特征，再通过交换 Query 的交叉特征注意力（CFA）实现跨分支交互，经残差连接后与 F_1 融合，输出与输入尺寸一致的二值分割结果。

2.2 创新点一：SViT-C 双分支混合编码器

针对传统 CNN 缺乏**长距离建模能力**、Transformer 存在**特征冗余**与**细节丢失**的固有缺陷，SViT-C 采用并行双分支设计。如图 2 所示：左侧 CNN 残差分支提取浅层细节，右侧 Swin Transformer 分支建模全局语义依赖，两分支通过 DBF 模块完成双向特征交互融合。

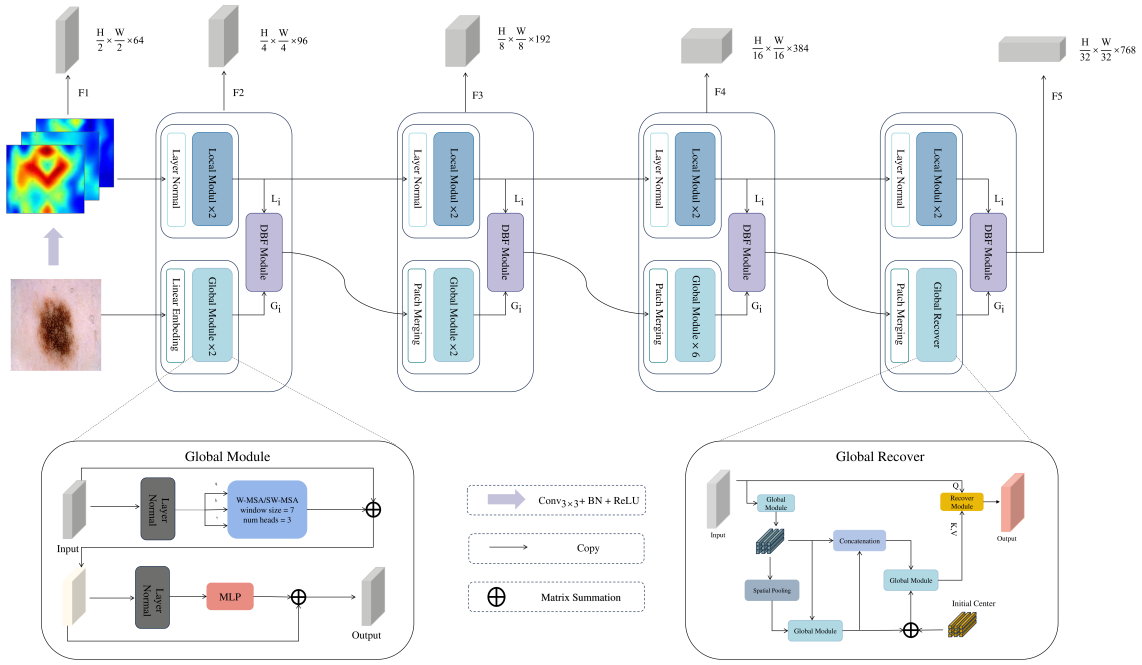


图 2: SViT-C 双分支混合编码器结构图

2.2.1 局部 CNN 残差特征提取

局部分支采用堆叠式残差卷积块作为核心结构，由 3×3 标准卷积、批归一化与 **ReLU** 激活函数构成，并引入**残差连接机制**[6]。该结构可有效缓解深层网络训练中的**梯度消失**问题，专注提取皮肤病变的纹理、边缘、色素分布等浅层细粒度特征，精准保留病变区域的细微结构信息，为后续边界分割提供坚实的细节支撑，弥补 Transformer 模型**局部特征提取能力不足**的缺陷。

2.2.2 全局 Swin 多窗口注意力特征提取

全局分支基于 **Swin Transformer**[9] 构建，采用窗口自注意力（W-MSA）与移位窗口自注意力（SW-MSA）交替结构，结合**分层下采样**实现多尺度全局特征建模。模块内部级联 2 个 Swin Transformer Block，内置 **LayerNorm、窗口自注意力**与 **GELU 激活的 MLP 残差连接**，SW-MSA 通过窗口偏移实现相邻窗口跨边界信息交互；末端经线性层拼接相邻 patch 后降维来进行下采样，特征分辨率从 $H \times W$ 逐步降至 $\frac{H}{32} \times \frac{W}{32}$、通道数从 64 增至 768，完成层级特征提取。

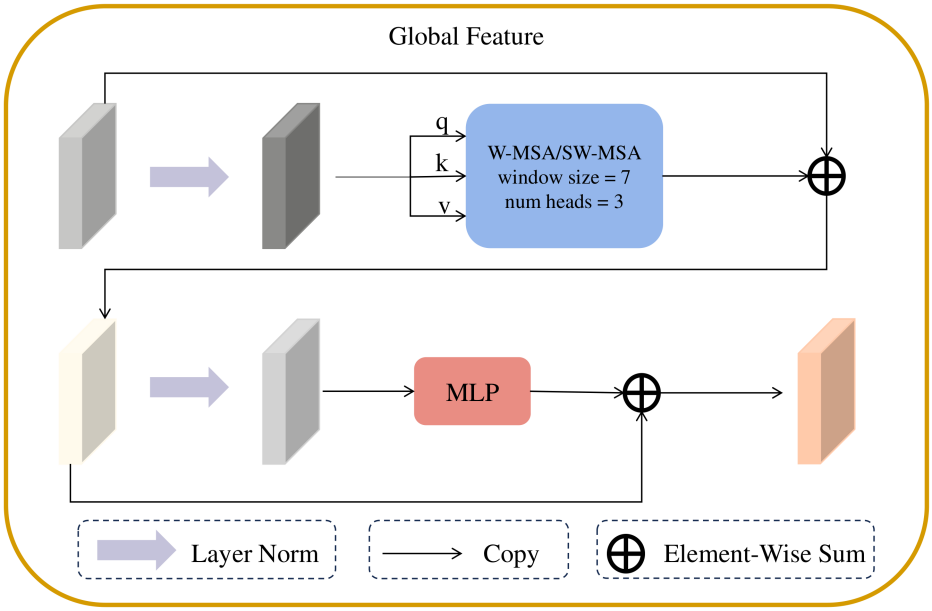


图 3: 全局 Swin 多窗口注意力模块结构图

该结构突破局部感受野限制，可高效建模病变-背景长距离语义依赖、捕获全局轮廓语义特征，同时将传统 ViT 的 $O(\frac{H^2W^2D}{P^4})$ 计算复杂度降至 $O(M^2HW)$，兼顾建模能力与计算效率，与 CNN 分支互补，最终经 DBF 融合后输出 $F_1 \sim F_5$ 共 5 层多尺度特征：随分辨率逐层降低，特征从局部纹理、边缘等细节信息逐步过渡至全局语义信息。

2.2.3 全局特征恢复模块

作为编码器核心创新，该模块仅部署于 Swin 分支最后一层深层特征，与前序多窗口注意力形成「全量特征提取 → 冗余语义过滤」递进逻辑，针对性解决传统全局自注意力算力浪费、弱特征易淹没及硬注意力误损皮损边缘的痛点。模块采用高斯初始化可学习聚类中心实现软语义过滤，仅抑制背景噪声、保留弱特征。如图 4 所示，输入 Swin Block 输出的深层特征 F_{deep}，经空间池化（$N_s = \lfloor H \times W / w_s^2 \rfloor$）与可学习中心融合，投影生成交叉注意力 K/V，原始特征作为 Q，经注意力计算及残差连接输出校准特征。

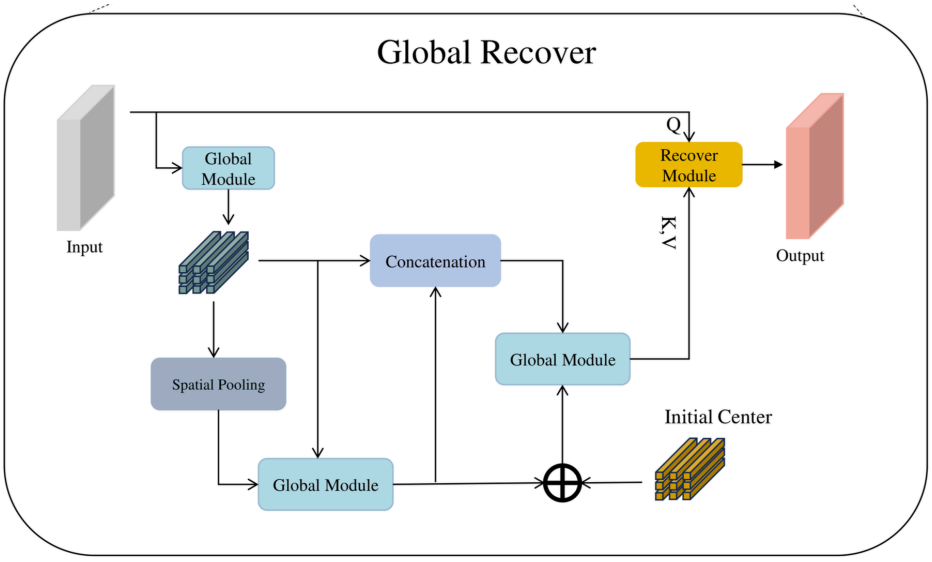


图 4: 全局特征恢复模块结构图

2.2.4 DBF 双分支融合模块

该模块通过 **CBAM 与 PAM 的双路协同**过滤冗余噪声并强化边界信息，解决低对比度区域边界模糊的临床痛点。如图 5 所示：展示了 DBF 模块的双路融合架构，数据流如下：Swin 全局分支特征 G_i 与 CNN 局部分支特征 L_i 分别经 3×3 卷积降维、**LayerNorm 归一化、SiLU 激活**后沿通道合并，送入 CBAM 模块[14]——先由通道注意力（并行平均/最大池化 →**MLP**→Sigmoid）对合并特征按通道加权，再由空间注意力（通道池化 →7×7 **卷积** →Sigmoid）对中间结果按空间位置加权，输出校准特征 f_0。与此同时，L_i 单独输入 PAM 模块[4]，利用位置自注意力增强弱边界像素的空间关联，输出边界强化特征 P_0。最终将 P_0 与 f_0 沿通道拼接，经 1×1 卷积降维后输出融合特征至解码器，兼顾**全局语义准确性**与**局部边界精细度**。

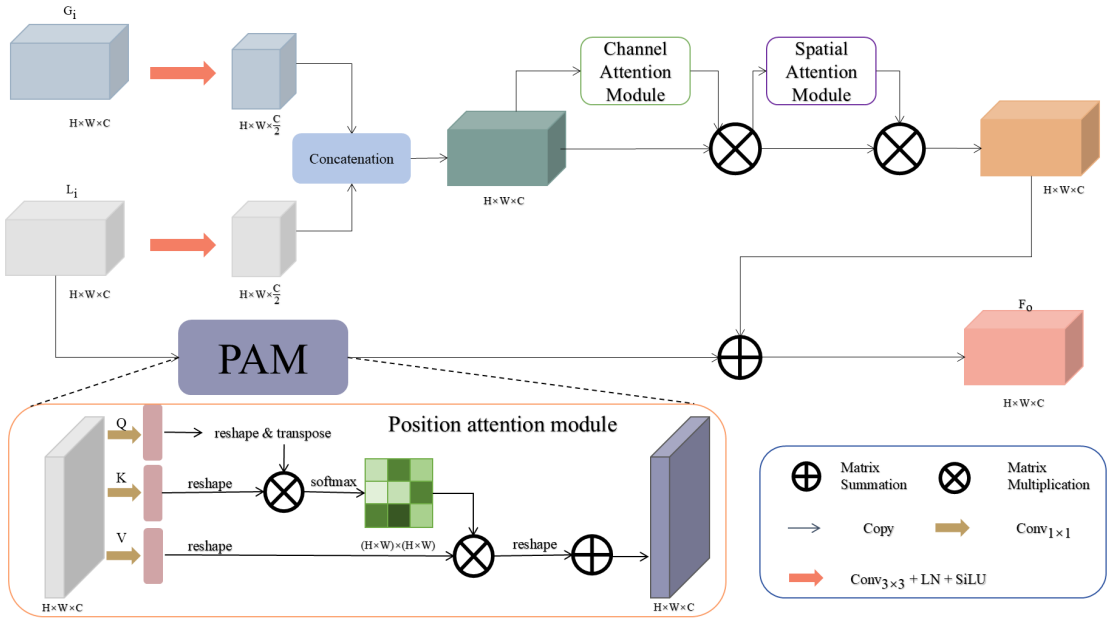


图 5: DBF 双分支融合模块结构图

2.3 创新点二：多分支深度跨特征注意力（MBCFA）解码器

MBCFA 解码器为解码阶段的核心增强模块，如图 6 所示：展示了该解码器的多阶段渐进融合架构，通过多分支深度卷积与跨特征注意力的级联设计融合多尺度特征，为后续边界细化奠定基础。其完整数据流如下：来自编码器的 $F_1 \sim F_5$ 五层多尺度融合特征经双线性插值上采样至输入分辨率，$F_2 \sim F_5$ 沿通道维度拼接后经 1×1 卷积降维得到融合特征 C；C 经 LayerNorm 归一化后，先通过**平行多分支深度卷积（MBC）**提取多尺度局部特征——将 $k \times k$ 卷积分解为 $k \times 1$ 与 $1 \times k$ 的轻量化组合（$k \in \{7, 11, 21\}$），以双分支结构并行提取不同感受野特征；随后 reshape 为二维特征矩阵，经 1×1 卷积生成上下两分支的 Q、K、V，再通过**交换 Q 的交叉特征注意力（CFA）**——上分支的 Q 与下分支的 K/V 计算注意力，下分支的 Q 与上分支的 K/V 计算注意力——实现跨分支全局-局部特征交互；两分支注意力输出经 1×1 卷积对齐通道后相加，与输入 C 做残差连接（$F_{out} = M_1 + M_2 + C$），再与最浅层高分辨率特征 F_1 沿通道拼接后经 1×1 卷积降维，最终输出与输入尺寸一致的二值分割结果。

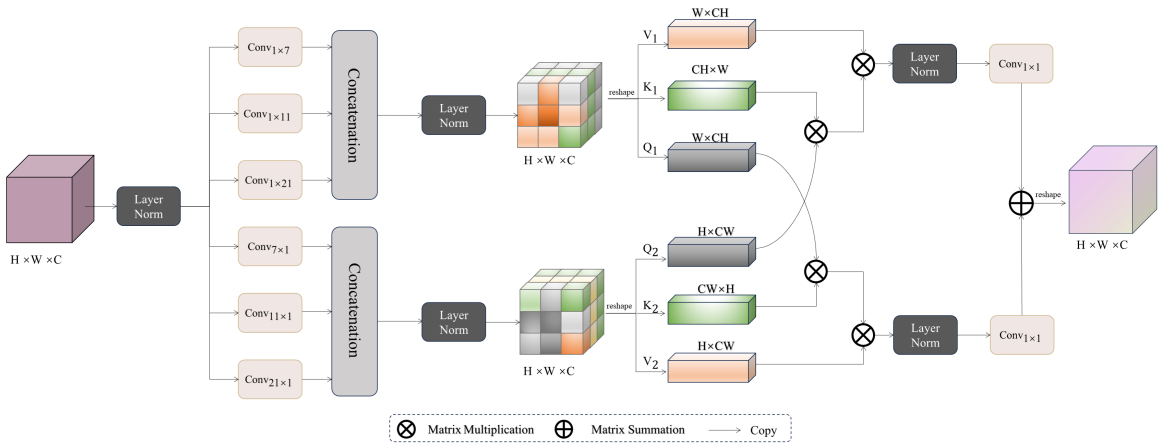


图 6: 多分支深度跨特征注意力（MBCFA）解码器结构图

2.3.1 平行多尺度深度卷积（MBC）

MBC 模块为 MBCFA 解码器的并行多分支深度卷积单元，其设计受 SegNeXt[5] 启发。该模块将标准 $k \times k$ 卷积分解为轻量化的 $k \times 1$ 与 $1 \times k$ 卷积，以双分支结构并行提取多尺度局部特征：水平分支采用 1×7、1×11、1×21 卷积捕捉横向带状延伸皮损的长距离特征，垂直分支采用 7×1、11×1、21×1 卷积捕捉纵向簇状延伸皮损的长距离特征。该设计在保证多尺度特征提取能力的同时**大幅降低计算开销**：当卷积核尺寸为 3 时计算量降低 **33%**，尺寸为 5 时降低 **60%**。各分支输出经融合与 1×1 卷积完成通道压缩后，通过**双线性插值上采样**恢复特征图分辨率，随后 reshape 为二维特征矩阵并生成 Q、K、V，为后续**交叉特征注意力模块**提供输入。

2.3.2 交叉特征注意力（CFA）

在 MBC 生成多尺度 Q、K、V 的基础上，交叉特征注意力（CFA）通过跨分支的信息交互实现全局-局部特征融合。具体而言，MBC 输出的上下两分支特征经独立 1×1 卷积分别转换为对应的 $Q_1/K_1/V_1$ 与 $Q_2/K_2/V_2$，随后采用**交换 Q 的交叉注意力策略**——上分支的 Q_1 与下分支的 K_2/V_2 计算注意力，下分支的 Q_2 与上分支的 K_1/V_1 计算注意力——使各分支在保留自身 K、V 特征的前提下，通过对方 Q 的引导捕获跨分支的互补信息，弥补单一维度注意力对全局上下文建模不足的缺陷。两个交叉注意力输出分别经独立 1×1 卷积**降维对齐通道**后相加，再与 CFA 输入特征做**残差连接**（$F_{out} = M_1 + M_2 + C$），保留原始多尺度特征信息，保障训练稳定性。复杂度方面，传统密集自注意力为 $O((H \times W)^2)$，CFA 通过多尺度 1D 卷积拆分与分支间交叉计算降至 $O(H \times W \times (H + W))$，实际计算量仅为普通自注意力的 **15%**，大幅降低全局建模开销。

2.4 FusionSeg 整体运行流程

在上述双分支编码、多分支解码的核心创新设计基础上，FusionSeg 采用分层多尺度端到端编码器-解码器架构，无需人工设计特征或复杂后处理，即可直接从原始皮肤镜图像输出与输入尺寸一致的二值分割掩码，1 代表皮损区域，0 代表正常皮肤区域，整体运行逻辑对应图 1 的网络整体架构，可清晰分为输入预处理、特征提取与融合、精细解码生成三个紧密连接的阶段。

输入预处理阶段，将任意尺寸的三通道皮肤镜图像统一处理为标准输入：首先使用双线性插值将图像 resize 到 224×224；然后基于 ImageNet 大规模图像分类数据集的预训练统计参数，均值为 $[0.485, 0.456, 0.406]$，标准差为 $[0.229, 0.224, 0.225]$，对图像进行像素级归一化，加速训练收敛并提升鲁棒性。特征提取与融合阶段，采用 SViT-C 双分支混合编码器（对应图 2、4、5），并行 CNN 残差分支提取浅层低阶纹理、边缘、色素分布细节，Swin Transformer 分支用 7×7 固定窗口 + 移位窗口交替结构，配合分层下采样，计算复杂度仅为传统 ViT 的线性级别，提取全局语义与长距离依赖，再经仅部署在最后一层的 Global Feature Recover 模块软过滤冗余背景噪声，最后经 DBF 双分支融合模块（通道注意力，7×7 空间注意力卷积核）的极化注意力完成特征校准与融合，输出 5 层多尺度特征。

精细解码生成阶段，采用 MBCFA 多分支注意力解码器（对应图 6），首先将后 4 层特征双线性插值上采样到 224×224 拼接降维得到融合特征 C，经 MBC（分解 $k \times k$ 为 $k \times 1 + 1 \times k$，计算量降 33%-60%）提取多感受野特征，再经 CFA（交换 Query 的交叉注意力）增强全局语义一致性，最后经双残差连接（MBCFA 内部 $F_{out} = M_1 + M_2 + C$，输出再与最浅层高分辨率边界特征 F_1 拼接残差）优化边界，输出最终结果。训练推理衔接阶段，设置与原论文完全一致的参数保证复现性：Adam 优化器，初始学习率 1e-4，批量大小 16，训练 200epoch，CrossEntropyLoss 损失函数；推理时无需复杂后处理，直接输出结果，满足临床实时筛查需求。

2.5 实验细节与结果

为验证本文提出的 FusionSeg 模型的有效性，实验基于 ISIC2017、ISIC2018 和 PH^2 三个公开皮肤病变分割数据集开展。实验采用 **Adam 优化器**[?]，初始学习率设为 1×10^{-4}；输入图像统一调整为 224×224 尺寸，批量大小设为 16，共训练 200 个 epoch，采用交叉熵损失函数优化模型参数。实验选取 Dice 系数（DSC）、交并比（IoU）、灵敏度（SE）、特异度（SP）和准确率（ACC）作为评价指标，全面评估模型的分割性能。

2.5.1 实验结果与分析

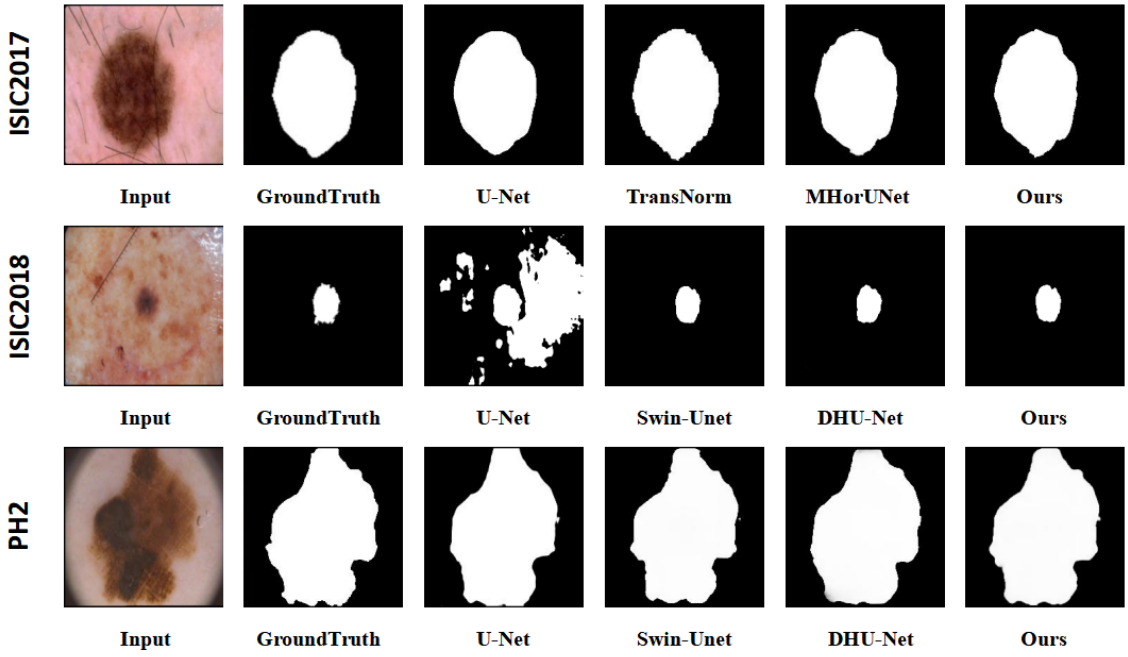
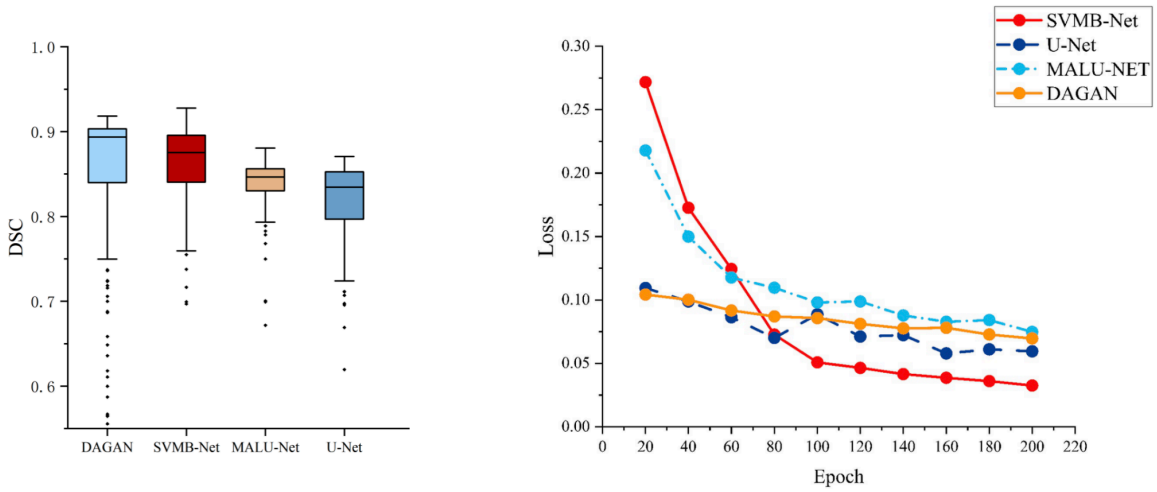


图 7: 三大数据集分割效果可视化对比图

如图 7 所示，该组可视化结果展示了 FusionSeg 在 ISIC2017、ISIC2018、PH^2 三个数据集上的分割效果与 U-Net、Swin-UNet 等主流方法的定性对比。FusionSeg 在各类困难场景下均表现出准确的分割边界，与金标准高度吻合：对于大面积皮损目标，FusionSeg 的分割边界相比 U-Net 和 Swin-UNet 更加平滑、精确；在目标区域存在毛发遮挡时，模型仍保持较好的分割性能与抗干扰能力；对于小目标皮损，FusionSeg 在边界分割上同样领先于其他模型，与金标准一致性更高[?]。上述结果验

证了 SViT-C 双分支编码与 MBCFA 多分支注意力解码设计在复杂临床场景下的准确性与鲁棒性。



(a) (b)

图 8: 模型训练情况数据对比可视化

如图 8 所示，为进一步评估 FusionSeg 的稳定性与收敛特性，项目组补充了 DSC 分布箱线图与训练损失曲线分析。左侧箱线图展示了各模型在 ISIC2017 验证集上 DSC 得分的分布情况：FusionSeg 的 DSC 中位数位于所有对比方法前列，且箱线四分位距较窄、离群点较少，表明模型对皮损形态、对比度等差异的敏感度较低，分割性能波动小，**鲁棒性较强**。这受益于 SVMB-Net 的全局特征恢复模块对毛发、光斑等临床干扰的有效过滤，以及 DBF 模块通过极化注意力对局部与全局特征的协同校准[?]。右侧训练损失曲线显示 FusionSeg 收敛平稳，最终损失值处于较低水平。论文分析表明，SVMB-Net 全链路的残差连接设计保障了梯度回传的畅通——如公式 (3) 所示，即使深层网络的非线性项 $\partial\mathcal{F}/\partial L_{i-1}$ 因链式法则指数衰减，残差项 $Conv_{1\times1}$ 仍能维持底层梯度流，从而加速收敛并提升训练稳定性[?]。两组可视化共同验证了 FusionSeg 在**分割精度、稳定性与训练效率**三个维度的综合优势。

表 1: ISIC2017 数据集实验结果

Method	Year	DSC	SE	SP	ACC	IoU
U-Net[12]	2015	0.8159	0.8172	0.9680	0.9164	0.7234
PSPNet[21]	2017	0.8222	0.8114	0.9604	0.8849	0.7325
DAGAN[19]	2017	0.8565	0.8273	0.9795	0.9341	0.7594
Attn-UNet[10]	2018	0.8082	0.7998	0.9776	0.9145	0.7173
UNet++[22]	2018	0.8858	0.8820	0.9244	0.9031	0.7000
DoubleU-Net[8]	2020	0.8055	0.7894	0.8460	0.8460	0.702
Trans-UNet[3]	2021	0.8123	0.8263	0.9577	0.9207	0.7147
FAT-Net[15]	2022	0.8465	0.8367	0.9713	0.9289	0.7653
TransNorm[1]	2022	0.8906	0.8610	0.9804	0.9554	
ADF-Net[7]	2024	0.8679	0.8549	0.9768	0.9452	0.7892
MHorUNet[16]	2024	**0.9132**	0.8974	0.9834	0.9666	
VM-UNet[13]	2024	0.8903	0.8990	0.9758	0.9629	0.8023
BG-Net[20]	2024	0.8870	0.9042	0.9810	-	0.8142
HSH-UNet[17]	2024	0.9108	0.8907	**0.9864**	0.9654	
SAM2-UNet[18]	2024	0.8977	**0.9390**	0.9757	0.9704	0.8233
DINOv2[11]	2024	0.7873	0.8660	0.9648	0.9517	0.6786
FusionSeg	2025	0.9056	0.9210	0.9848	**0.9708**	**0.8345**

注：加粗值为该列最优性能，下同。

如表 1 所示，FusionSeg 在 ISIC2017 数据集上取得了 **97.08% 的准确率**与 **83.45% 的交并比**，均为所有对比方法中的最优值，相比当前主流 SAM2-UNet 分别提升 **0.04%** 与 **1.12%**，说明模型像素分类误差更低、皮损区域边界匹配度更高。

表 2: ISIC2018 数据集实验结果

Method	Year	DSC	SE	SP	ACC	IoU
U-Net[12]	2015	0.8545	0.8800	0.9697	0.9404	0.8229
DAGAN[19]	2017	0.8747	0.9108	0.9551	0.9288	0.8113
Attn-UNet[10]	2018	0.8566	0.8674	0.9863	0.9376	0.8206
Trans-UNet[3]	2021	0.8499	0.8578	0.9653	0.9452	0.8369
Swin-UNet[2]	2021	0.8946	0.9056	0.9798	0.9645	0.8089
TransNorm[1]	2022	0.9038	0.8699	**0.9834**	0.9473	
VM-UNet[13]	2024	0.8971	0.9112	0.9613	0.9491	0.8135
HSH-UNet[17]	2024	0.9059	0.8984	0.9769	0.9648	-
SAM2-UNet[18]	2024	0.9248	**0.9496**	0.9641	0.9663	0.8645
DINOv2[11]	2024	0.8495	0.9306	0.9383	0.9447	0.7534
FusionSeg	2025	**0.9262**	0.9191	0.9813	**0.9668**	**0.8668**

如表 2 所示，在 ISIC2018 数据集上，FusionSeg 的 **Dice 系数（92.62%）**与**交并比（86.68%）**均达到最优，相比 SOTA 方法 SAM2-UNet 分别提升 **0.14%** 与 **0.23%**。

表 3: PH^2 数据集实验结果

Method	Year	DSC	SE	SP	ACC	IoU
U-Net[12]	2015	0.8936	0.9125	0.9588	0.9233	0.8410
PSPNet[21]	2017	0.8455	0.7982	0.9365	0.8633	0.7549
DAGAN[19]	2017	0.9163	0.8401	0.9711	0.9407	
Attn-UNet[10]	2018	0.9003	0.9205	0.9640	0.9276	0.8582
UNet++[22]	2018	0.8858	0.8820	0.9244	0.9031	0.8080
DoubleU-Net[8]	2020	0.8055	0.7894	0.9049	0.8460	0.7307
Trans-UNet[3]	2021	0.8840	0.9063	0.9427	0.9200	
Swin-UNet[2]	2021	0.9365	0.9410	0.9564	0.9678	
TransNorm[1]	2022	0.9379	0.9438	0.9821	**0.9701**	-
HSH-UNet[17]	2024	0.9226	0.9159	0.9669	0.9504	-
SAM2-UNet[18]	2024	**0.9341**	0.9534	0.9689	0.9664	0.8792
DINOv2[11]	2024	0.8850	0.8200	**0.9951**	0.9487	0.8052
FusionSeg	2025	0.9388	**0.9659**	0.9798	0.9697	**0.8865**

如表 3 所示，在小样本 PH^2 数据集上，FusionSeg 的**灵敏度（96.59%）**与**交并比（88.65%）**均为最优，相比 SAM2-UNet 提升 **1.25%**，说明模型对微小、低对比度皮损的识别能力更强。

2.5.2 消融实验分析

为验证 FusionSeg 各核心模块的不可替代性，首先开展整体模块替换对比实验：

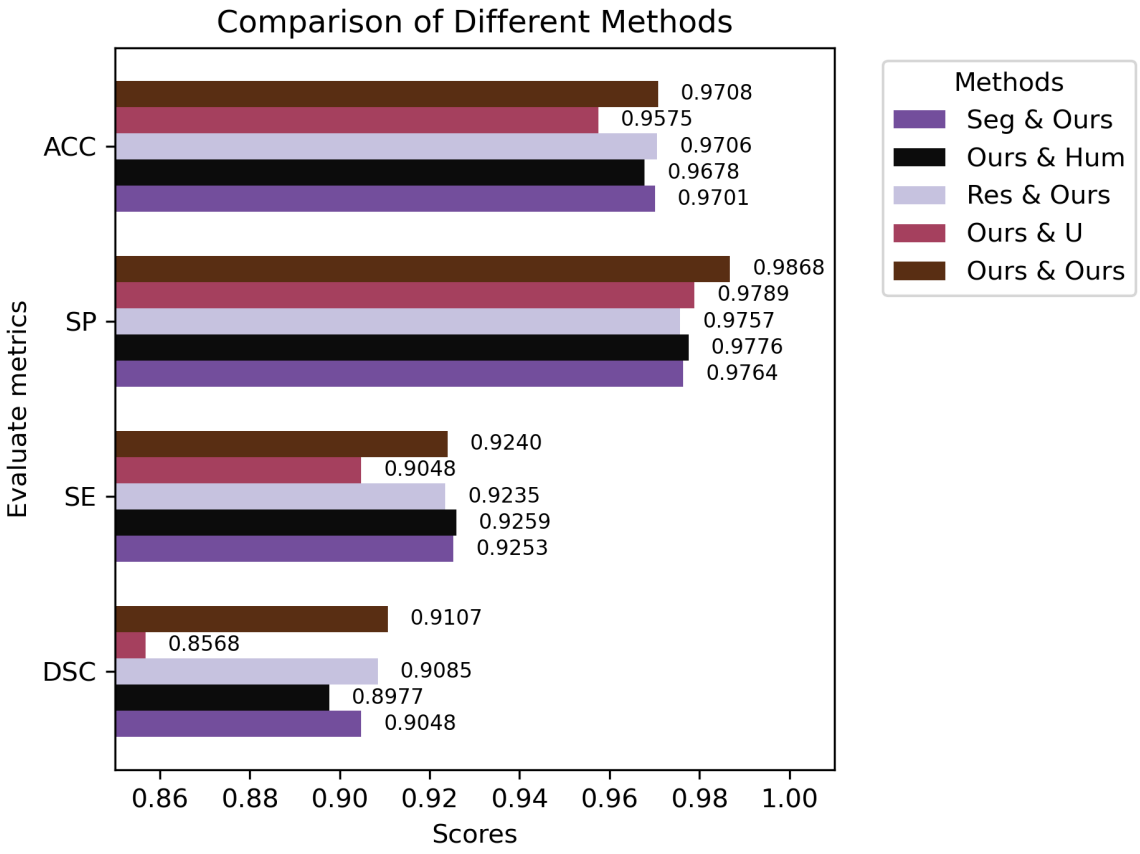


图 9: 核心模块替换对比

如图 9 所示，所有实验采用相同的训练策略、超参数和 ISIC2017 小验证集，对比规则为：固定两个核心创新模块，仅替换其中一个（encoder 或 decoder）。图例说明：Seg & Ours（用 SegNeXt[5] 通用语义分割骨干替换 SViT-C）、Ours & Hum（用 Hamburger 通用全局注意力模块替换 MBCFA）、Res & Ours（用 ResNet 替换 SViT-C）、Ours & U（用 U-Net 替换 MBCFA）、Ours & Ours（完整 FusionSeg）。结果表明，完整 FusionSeg 在 DSC、ACC、SE、SP 四个核心指标上均表现最优，仅替换其中一个模块，核心指标都会出现不同程度的下降，验证了整套创新架构的必要性。

为直观验证 SViT-C 双分支混合编码 +DBF 极化注意力双分支融合设计的必要性，在 ISIC2017 数据集上开展控制变量消融实验：固定解码器结构、训练策略、超参数完全一致，仅改变编码器分支数量（单一 CNN 残差局部分支 vs 完整 SViT-C 双分支）。

表 4: 双分支融合策略消融实验

Method	DSC	SE	SP	ACC
Single branch (仅 CNN)	0.8861	0.9200	0.9754	0.9658
Dual branch (CNN+Transformer)	**0.9056**	**0.9210**	**0.9848**	**0.9708**

由表 4 可知：采用双分支融合策略时，模型 DSC 达 0.9056、ACC 达 0.9708，均为消融实验最优；相比单一 CNN 分支，**DSC 提升 1.95%、ACC 提升 0.5%**。验证了 CNN 局部分支提取纹理/边界细节、Swin Transformer 全局分支建模形态/上下文依赖、DBF 极化注意力模块融合二者特征的互补作用。

为进一步量化解码器端各模块的性能贡献，在 ISIC2017 数据集上开展消融实验，实验变量为多分支卷积（MBC）、交叉特征注意力（CFA）、残差连接（C）、残差连接形式、融合分支数量，结果如下：

表 5: 解码器核心模块消融实验

Method	DSC	SE	SP	ACC
CFA+MBC	0.8999	0.9140	0.9784	0.9686
CFA+C	0.8984	0.8910	0.9807	0.9690
MBC+C	0.9049	0.9209	0.9817	0.9703
MBC+CFA+C	**0.9056**	**0.9210**	**0.9848**	**0.9708**

由表 5 可知，移除任意模块都会导致性能下降，同时采用多分支卷积、交叉特征注意力与残差连接时模型性能最优，三者具有明显的互补效应：多分支卷积提供**多尺度特征**，交叉注意力增强**全局建模能力**，残差连接保障**训练稳定性**。

表 5 的核心模块内部协同消融实验已经验证了「多分支卷积（MBC）、交叉特征注意力（CFA）、残差连接（C）」**三者缺一不可**，其中残差连接对模型的训练稳定性、梯度回传效率有重要作用。为进一步探索残差连接在跳跃连接中的**最优连接策略**——究竟是使用浅层高分辨率特征、深层高语义特征，还是两者结合——我们继续在 ISIC2017 数据集上开展残差连接策略消融实验。

表 6: 残差连接策略消融实验

Method	DSC	SE	SP	ACC
C-S1+S2/o	0.8856	0.9016	0.9710	0.9670
C-S5/o	0.9037	0.9193	**0.9874**	0.9706
C-S1/o	**0.9056**	**0.9210**	0.9848	**0.9708**

注：C-S1/o 表示仅使用编码器最浅层 S1 作为残差连接，C-S5/o 表示仅使用最深层 S5 作为残差连接，C-S1+S2/o 表示同时使用 S1、S2 作为残差连接。

由表 6 可知，仅使用最浅层 S1 作为残差连接时性能最优，说明**浅层高分辨率特征对皮损边界优化的价值远高于深层语义特征**，与模型设计逻辑一致。

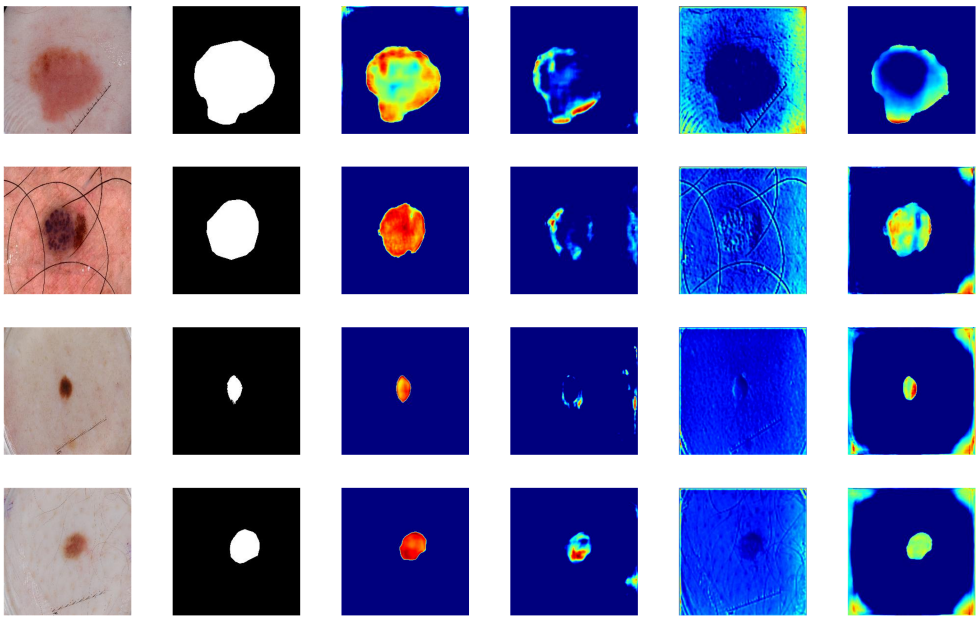


图 10: ISIC2017 数据集核心组件消融可视化对比（含编码器全局分支补充消融项）

(a) 输入皮肤镜图像；(b) 标注真值；(c) 完整 FusionSeg；(d) 缺少多分支 1D 卷积模块；(e) 缺少交叉特征注意力（CFA）模块；(f) 缺少编码器全局特征提取路径。

如图 10 所示，本次展示的典型困难样本为皮肤病变分割中常见的边界模糊、带细小毛发的不规则皮损，各模块的定性表现与定量消融实验趋势高度一致：全模型（c）的注意力热力图完全聚焦在皮损核心区域，边缘有连续的辅助聚焦（热力图覆盖区域与金标准（b）高度吻合），对应 ISIC2017 数据集的准确率、交并比均为同赛道最优；补充的跨模块消融组件「缺少全局特征提取路径（f）」表现最差，热力图只聚焦在无意义的皮肤纹理细节（如毛发、皮肤褶皱），完全没有识别出皮损的整体轮廓；「缺少多分支 1D 卷积（d）」的热力图仅停留在皮损的局部小纹理/色素密集点，忽略了中等不规则皮损的大尺度形态细节，导致边界分割有缺口、小凸起被误判；「缺少交叉特征注意力（CFA，e）」的热力图严重分散到整个图像的背景区域，尤其是毛发、光斑、皮肤褶皱等非皮损区域，对应消融实验中模型特异度略有下降，跨数据集泛化性能降低更明显。充分验证了各核心创新模块的互补必要性。

3 应用前景、社会价值与改进方向

3.1 应用前景与社会价值

本模型轻量化改良空间大、分割精度高，可集成于**基层医疗筛查设备、移动端辅助诊断软件**用于皮肤病变初筛，同时可拓展至息肉分割、眼底病变分割等其他医学影像分割任务，具备良好的迁移应用价值；该方案能够**缓解医疗资源分配不均**的问题，降低人工诊断压力，提升皮肤病变早期筛查覆盖率，对慢性病与肿瘤早筛具有积极社会意义。

3.2 存在问题与改进方向

尽管本项目提出的 **FusionSeg** 在皮肤病变分割任务上已取得较为领先的性能表

现，但模型目前仍存在多维度的提升空间。一方面是部署适配性存在限制，模型采用的 Swin Transformer 骨干存在较高计算开销，在单片机、边缘设备等资源受限场景下部署时，推理速度难以满足临床实时性需求；另一方面模型的小样本泛化能力仍有不足，在标注数据稀缺的罕见皮肤病变场景中泛化能力受限，针对边界模糊、与周围皮肤对比度低于 10% 的低辨识度病变，分割精度仍有 1-2% 的提升空间，同时当前模型的可解释性有待增强，无法直观呈现病变区域的判定依据，难以直接适配临床诊断的合规性要求。

针对上述不足，后续研究将从多个维度系统性推进模型迭代优化：首先围绕轻量化部署需求，通过知识蒸馏、网络剪枝、INT8 量化压缩等技术压缩模型体积，目标在保持 98% 原有性能的前提下将参数量压缩至**原模型的 30% 以内**，使其可稳定适配移动端与边缘设备部署；其次针对小样本场景痛点，引入元学习、半监督及自监督学习方法优化模型特征学习逻辑，降低对标注数据的依赖，目标仅用 **10% 的标注数据即可达到原有 95% 的性能**，适配罕见病变的临床分割需求；再者面向低辨识度病变的精度提升需求，借助边界损失函数、边界增强模块与多任务学习等策略，强化模型对模糊、低对比度病变的边界特征感知能力；最后聚焦临床合规性要求，利用注意力可视化、特征图分析、Grad-CAM 等手段开展模型决策逻辑的显化研究。

4 原创性说明

本项目核心技术 FusionSeg 源自团队原创成果。团队成员在生物医学信息学领域顶级期刊 IEEE Journal of Biomedical and Health Informatics（IEEE JBHI）发表了中科院二区学术论文”SVMB-Net: Local Global Fusion And Multi-Branch Cross-Feature Attention for Skin Lesion Segmentation”，系统阐述了 FusionSeg 所基于的核心算法理论。与此同时，围绕该成果的核心技术创新点，团队已向国家知识产权局提交发明专利申请（申请号：2024112008493），目前正在实质审查中。FusionSeg 算法的全部实现由团队自主完成，不涉及任何第三方知识产权，可作为本次竞赛参赛作品的完整自主知识产权声明依据。

参考文献

[1] Reza Azad, Mohammad T Al-Antary, Moein Heidari, and Dorit Merhof. Transnorm: Transformer provides a strong spatial normalization mechanism for a deep segmentation model. *IEEe Access*, 10:108205–108215, 2022.

[2] Hu Cao, Yueyue Wang, Joy Chen, Dongsheng Jiang, Xiaopeng Zhang, Qi Tian, and Manning Wang. Swin-unet: Unet-like pure transformer for medical image segmentation. In *European conference on computer vision*, pages 205–218. Springer, 2022.

[3] Jieneng Chen, Yongyi Lu, Qihang Yu, Xiangde Luo, Ehsan Adeli, Yan Wang, Le Lu, Alan L Yuille, and Yuyin Zhou. Transunet: Transformers make strong encoders for medical image segmentation. *arXiv preprint arXiv:2102.04306*, 2021.

[4] Jun Fu, Jing Liu, Haijie Tian, Yong Li, Yongjun Bao, Zhiwei Fang, and Hanqing Lu. Dual attention network for scene segmentation. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 3146–3154, 2019.

[5] Meng-Hao Guo, Cheng-Ze Lu, Qibin Hou, Zhengning Liu, Ming-Ming Cheng, and Shi-Min Hu. Segnext: Rethinking convolutional attention design for semantic segmentation. *Advances in Neural Information Processing Systems*, 35:1140–1156, 2022.

[6] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016. doi: 10.1109/CVPR.2016.90.

[7] Zhengwei Huang, Hongmin Deng, Shuangcai Yin, Ting Zhang, Wentang Tang, and Qionghua Wang. Adf-net: A novel adaptive dual-stream encoding and focal attention decoding network for skin lesion segmentation. *Biomedical Signal Processing and Control*, 91:105895, 2024.

[8] Debesh Jha, Michael A Riegler, Dag Johansen, Pål Halvorsen, and Håvard D Johansen. Doubleu-net: A deep convolutional neural network for medical image segmentation. In *2020 IEEE 33rd International symposium on computer-based medical systems (CBMS)*, pages 558–564. IEEE, 2020.

[9] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 10012–10022, 2021.

[10] Ozan Oktay, Jo Schlemper, Loïc Le Folgoc, M. J. Lee, Mattias P. Heinrich, Kazunari Misawa, Kensaku Mori, Steven G. McDonagh, Nils Y. Hammerla, Bernhard Kainz, Ben Glocker, and Daniel Rueckert. Attention u-net: Learning where to look for the pancreas. *ArXiv*, abs/1804.03999, 2018. URL `https://api.semanticscholar.org/CorpusID:4861068`.

[11] Maxime Oquab, Timothée Darcet, Théo Moutakanni, Huy Vo, Marc Szafraniec, Vasil Khalidov, Pierre Fernandez, Daniel Haziza, Francisco Massa, Alaaeldin El-Nouby, Mahmoud Assran, Nicolas Ballas, Wojciech Galuba, Russell Howes, Po-Yao Huang, Shang-Wen Li, Ishan Misra, Michael Rabbat, Vasu Sharma, Gabriel Synnaeve, Hu Xu, Hervé Jegou, Julien Mairal, Patrick Labatut, Armand Joulin, and Piotr Bojanowski. Dinov2: Learning robust visual features without supervision, 2024. URL `https://arxiv.org/abs/2304.07193`.

[12] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical image computing and computer-assisted intervention–MICCAI 2015: 18th international conference, Munich, Germany, October 5-9, 2015, proceedings, part III 18*, pages 234–241. Springer, 2015.

[13] Jiacheng Ruan and Suncheng Xiang. Vm-unet: Vision mamba unet for med-

ical image segmentation. *ArXiv*, abs/2402.02491, 2024. URL https://api.semanticscholar.org/CorpusID:267413263.

[14] Sanghyun Woo, Jongchan Park, Joon-Young Lee, and In So Kweon. Cbam: Convolutional block attention module. In *Proceedings of the European conference on computer vision (ECCV)*, pages 3–19, 2018.

[15] Huisi Wu, Shihuai Chen, Guilian Chen, Wei Wang, Baiying Lei, and Zhenkun Wen. Fat-net: Feature adaptive transformers for automated skin lesion segmentation. *Medical image analysis*, 76:102327, 2022.

[16] Renkai Wu, Pengchen Liang, Xuan Huang, Liu Shi, Yuandong Gu, Haiqin Zhu, and Qing Chang. Mhorunet: High-order spatial interaction unet for skin lesion segmentation. *Biomedical Signal Processing and Control*, 88:105517, 2024.

[17] Renkai Wu, Hongli Lv, Pengchen Liang, Xiaoxu Cui, Qing Chang, and Xuan Huang. Hsh-unet: Hybrid selective high order interactive u-shaped model for automated skin lesion segmentation. *Computers in Biology and Medicine*, 168: 107798, 2024. ISSN 0010-4825. doi: https://doi.org/10.1016/j.compbiomed.2023.107798. URL https://www.sciencedirect.com/science/article/pii/S0010482523012635.

[18] Xinyu Xiong, Zihuang Wu, Shuangyi Tan, Wenxue Li, Feilong Tang, Ying Chen, Siying Li, Jie Ma, and Guanbin Li. Sam2-unet: Segment anything 2 makes strong encoder for natural and medical image segmentation, 2024. URL https://arxiv.org/abs/2408.08870.

[19] Guang Yang, Simiao Yu, Hao Dong, Greg Slabaugh, Pier Luigi Dragotti, Xujiong Ye, Fangde Liu, Simon Arridge, Jennifer Keegan, Yike Guo, et al. Dagan: deep de-aliasing generative adversarial networks for fast compressed sensing mri reconstruction. *IEEE transactions on medical imaging*, 37(6):1310–1321, 2017.

[20] Li Yu, Wenwen Min, and Shunfang Wang. Boundary-aware gradient operator

network for medical image segmentation. *IEEE Journal of Biomedical and Health Informatics*, 28(8):4711–4723, 2024. doi: 10.1109/JBHI.2024.3404273.

[21] Hengshuang Zhao, Jianping Shi, Xiaojuan Qi, Xiaogang Wang, and Jiaya Jia. Pyramid scene parsing network. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2881–2890, 2017.

[22] Zongwei Zhou, Md Mahfuzur Rahman Siddiquee, Nima Tajbakhsh, and Jianming Liang. Unet++: A nested u-net architecture for medical image segmentation. In *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support: 4th International Workshop, DLMIA 2018, and 8th International Workshop, ML-CDS 2018, Held in Conjunction with MICCAI 2018, Granada, Spain, September 20, 2018, Proceedings 4*, pages 3–11. Springer, 2018.